


# Chapter 6. LMMs

---

*Wiley Series in Probability and Statistics*

## Generalized, Linear, and Mixed Models

*Charles E. McCulloch, Shayle R. Searle*



# 1. A General Model

## a. Introduction

### • Linear Model

-  $E(y) = X\beta$ , 단  $\beta$ 는 미지의 모수

-  $E(y_{ij}) = \mu + \alpha_i$

$\mu$ : General mean

$\alpha_i$ : 플라시보 환자의 반응변수 effect

$\alpha_2$ : 약물 받은 환자의 반응변수 effect

이때,  $\mu, \alpha_i, \alpha_2$ 는 fixed effect

$$E(y) = X\beta, \quad \beta = \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \end{bmatrix}$$

### • Linear Mixed Model

$$E(y_{ij}) = \mu + \alpha_i + \beta_j + C_{ij}$$

$\alpha_i$ : i병원의 랜덤 effect

$\beta_j$ : j약물 수준의 fixed effect

$C_{ij}$ : 상호작용의 random effect

$\Rightarrow$  LMM: fixed effect  $\oplus$  random effect.

### • Random model

: fixed effect 없을 때, 단  $\mu$ 는 포함

• fixed effect : y의 평균 모델링

### • Random effect

: y의 분산 - 공분산 구조 govern

$\text{Var}(y_{N \times 1})$ 의 원소를  $\frac{N(N-1)}{2}$ 개 결정하 하는 작업 단순화

$\rightarrow$  Random effect 없으면,  $\text{Var}(y)$  원소는 다양한 형태로 다뤄야 함.

$\rightarrow$  Random effect 사용하면 데이터에 영향을 미치는 것으로 알려진 factor에 기인하는 분산·공분산 편하게 다루는 0

## b. Basic Properties

- LM :  $E(y) = X\beta$  ,  $\beta$ 는 fixed effect

- LMM :  $E(y) = X\beta + zu$

$z$ 는 알려진 행렬,

$u$ 는 데이터 벡터 ( $y$ )에서 발생한 random effect vec.

→  $u$ 는 random variable

: 관측할 수 없는 실현값에 대해 조건부 모델 지정

$$E(y|u) = X\beta + zu.$$

$$pf) E(y|u) = E(X\beta + zu + \varepsilon|u)$$

$$= E(X\beta|u) + E(zu|u) + \underbrace{E(\varepsilon|u)}_{=0 (\because \varepsilon \perp u)} \\ = X\beta + zu$$

⇒ 확률 변수  $u$ 에 대한 실현값  $u$ 를 사용하면,  $E(y|u) = u$

$$\Leftrightarrow E(y|u)$$

$u \sim (0, D)$  :  $E(u) = 0$ ,  $\text{Var}(u) = D$ 로 가정한다.

pf) Goal :  $E(u) = 0$ .

$$\text{let}, E(u) = \tau$$

$$E(y|u) = X\beta + zu = X\beta + z\tau + z(u - \tau)$$

$$\text{let}, X^* = [X \ z], \ \beta^* = [\beta' \ \tau']', \ u^* = u - \tau$$

$$E(y|u) = X\beta + z\tau + z(u - \tau) = X^*\beta^* + zu^*$$

$$\rightarrow E(u^*) = E(u - \tau) = E(u) - \tau = \tau - \tau = 0$$

$$\therefore E(y|u) = X\beta + zu, \ E(u) = 0$$

cf.  $\text{Var}(y|u)$  vs  $\text{Var}(\varepsilon)$

-  $\text{Var}(y|u)$  : 일반적 표현 → 일반화 선형모형

-  $\text{Var}(\varepsilon)$  : 회귀 모형에서 사용하는 오차항

일반화 선형 모형에서 정규성 가정시에만 사용.

$$\rightarrow \text{Var}(y|u) = \text{Var}(X\beta + zu + \varepsilon|u) = \text{Var}(\overbrace{zu}^0) + \text{Var}(\varepsilon|u) = \text{Var}(\varepsilon|u) \\ \therefore u \text{가 지정됨.} \\ = \text{Var}(\varepsilon|u) = R \\ \hookrightarrow R \text{이 } u \text{의 함수가 아니면 indep.}$$

$$\text{Var}(y|u) = R \text{ 가정}$$

$$\Rightarrow y \sim (X\beta, zDz' + R)$$

pf) Goal :  $\text{Var}(y) = zDz' + R$ .

$$\text{Var}(y) = \text{Var}(X\beta + zu + \varepsilon)$$

$$= z^2 \text{Var}(u) + \text{Var}(\varepsilon) + z \cdot \text{Cov}(u, \varepsilon) \quad (\because X\beta \text{ 상수})$$

$$= z^2 \cdot D + R + 0 \quad (\because u \perp \varepsilon)$$

$$= zDz' + R$$

pf2) Goal :  $\text{Var}(y) = zDz' + R$ .

$$\text{Var}(y) = E[\text{Var}(y|u)] + \text{Var}[E(y|u)]$$

$$= E(R) + \text{Var}(X\beta + zu)$$

$$= R + z^2 \text{Var}(u) = R + z^2 \cdot D = R^2 + zDz'$$

⇒ fixed effect는 평균만 입력 ( $X\beta$ )

random effect model 행렬과 분산은 y분산만 입력

## 2. Attributing Structure to $\text{Var}(y)$

$$V = \text{Var}(y) = ZDZ' + R$$

### a. Example

- 데이터 : 뉴욕 15개 고등학교에서 각 4개의 9학년 학급에  
주어진 수학 시험 성적

→ 고정효과인 남/여의 차이 이외에도 변동요인 有

① 학교 간    ② 각 학교내 학급간    ③ 각 학급내 학생간

→ T학교 내 J학급의 t성별의 K학생의 성적 :  $y_{tjk}$

$$E(y_{tjk} | S_t, G_J) = \beta_t + S_t + G_J$$

$\beta_t$ : 성별 t에 대한 fixed effect

$S_t$ :  $T=1, \dots, 15$ 에 대한 학교 효과 (random effect)

$G_J$ :  $J=1, \dots, 4$ , T학교에 대한 J번째 학급효과 (random effect)

$P_{tjk}$ : 개인 학생에 대해  $\beta_t, S_t, G_J$ 로 설명되지 않는 모든 것

↓

$\beta$ :  $\beta_m$ (남성),  $\beta_f$ (여성) 두 원소 존재

$u$ : 15개의  $S_t$  효과와 60개 ( $15 \times 4$ )  $G_J$  효과

### b. Taking Covariances between factors as zero

$$u = \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} = \begin{bmatrix} \{c S_t\}_{t=1}^{15} \\ \{c G_J\}_{J=1}^4 \{t=1\}^{15} \end{bmatrix}$$

$$Z = [Z_1 \ Z_2]$$

$$\therefore Zu = Z_1 u_1 + Z_2 u_2$$

$$D = \text{Var}(u) = \begin{bmatrix} \text{Var}(u_1) & \text{Cov}(u_1, u_2) \\ \text{Cov}(u_2, u_1) & \text{Var}(u_2) \end{bmatrix} = \begin{bmatrix} D_1 & D_{12} \\ D_{21} & D_2 \end{bmatrix}$$

$$\rightarrow D_{21} = D_{12}'$$

$$\therefore E(y|u) = X\beta + Z_1 u_1 + Z_2 u_2$$

$$V = ZDZ' + R$$

$$= Z_1 D_1 Z_1' + Z_2 D_2 Z_2' + Z_1 D_{12} Z_2' + Z_2 D_{21} Z_1' + R$$

$$\rightarrow R = \text{Var}(y|u)$$

:  $P_{tjk}$  항의 분산 - 공분산 행렬

학생간 변동성 +  $S_t$ 와  $G_J$ 에 기인하지 않는 변동성

• 2-random factor  $\rightarrow$  r Random factors 확장!

$$u = \{c, u_i\}_{i=1}^r$$

$$D = \text{Var}(u) = \{D_{ii'}\}_{i,i'=1}^r$$

$$Z = [Z_1, Z_2, \dots, Z_r] = \{Z_i\}_{i=1}^r$$

$$\rightarrow E(y|u) = X\beta + \sum_{i=1}^r Z_i u_i$$

$$V = \sum_{i=1}^r Z_i D_{ii} Z_i' + \sum_{\substack{i=1 \\ i \neq i'}}^r \sum_{i'=1}^r Z_i D_{ii'} Z_{i'}' + R$$

$$D_{ii} = \text{Var}(u_i), \quad D_{ii'} = \text{Cov}(u_i, u_{i'})$$

$\rightarrow$  예제에서  $D_{11}$ : 학교들의 분산-공분산 행렬

$D_{12}$ : 학교와 학급의 분산-공분산 행렬

$\downarrow$

이러한 공분산=0 이 되는데 합리적

why? 학교 효과  $S_j$ 와 학급 효과  $G_{ij}$ 의 학교는 다른 학교

Correlation 는 없다.

$D_{12}$ : 한 학교 효과  $S_i$ 와 같은 학교내 학급 효과  $G_{ij}$ 의 공분산

랜덤 효과 사용해 데이터의 모든 변동성 파악  $\rightarrow$  공분산=0

$$\therefore D_{12} = 0$$

• General case로 확장

$i \neq i'$ 에 대해  $D_{ii'} = 0 \rightarrow D_{ii}$ 를  $D_i$ 로 씀

$$D = \{D_i\}_{i=1}^r \quad V = \sum_{i=1}^r Z_i D_i Z_i' + R$$

## C. Traditional Variance Components model

### ① Customary notation

- 예제에서, 학교간 공분산 = 0, 학교들의 등분산성 가정한다면,

$$15 \text{ 개의 학교에 대해 } D_1 = \sigma_s^2 I_{15} \quad \text{--- ①}$$

- 1학교내 4개의 학급에도 비슷하게 가정하면,

$$\text{Var}[C_{11} \ C_{12} \ C_{13} \ C_{14}]' = \sigma_c^2 I_4$$

- 한 학교 내 학급들이 모든 다른 학교내 학급들과 독립가정 합리적.

$$D_2 = \int_d \text{Var}(u_i)_{i=1}^{15} = \int_d \sigma_c^2 I_4_{i=1}^{15}$$

- 더 간단한 가정: 한 학교내 4개 학급이 15개 학교에 대해

$$\text{동일한 분산.} \rightarrow \sigma_i^2 = \sigma_c^2 \quad \forall i$$

$$D_2 = \sigma_c^2 I_{60} \quad \text{--- ②}$$

- ①과 ②에 의해,  $R = \sigma_s^2 I_{1200}$

: 전통적인 Variance Components 모형에 대한 표준 구조 만들어냄.

↓

- General case : random effects  $r$  개

$$D = \int_d \sigma_i^2 I_{\theta_i} \Big|_{i=1}^r \leftarrow r \text{의 랜덤 요인에 } \theta_i \text{ 효과 가정}$$

$u_i$ 의 order은  $\theta_i \times 1$

$$V = \underbrace{\sum_{i=1}^r z_i z_i' \sigma_i^2 + \sigma^2 I_N}_{\text{---}} \leftarrow y \text{의 order : } N \times 1$$

### ② Amended notation

$$-\sigma_s^2 \equiv \sigma^2, \quad z_0 \equiv I_N, \quad \theta_0 = N$$

$$D_* = \begin{bmatrix} \sigma_s^2 I_{\theta_0} & 0 \\ 0 & D \end{bmatrix} = \int_d \sigma_i^2 I_{\theta_i} \Big|_{i=0}^r$$

$$V = \sum_{i=1}^r z_i z_i' \sigma_i^2 + \sigma^2 I_N = \sum_{i=0}^r z_i z_i' \sigma_i^2 = z_* D_* z_*'$$

$$\text{이때, } z_* = [z_0 \ z_1 \ \dots \ z_r] = [z_0 \ z]$$

-  $z_0$ 에 대응되는  $N \times 1$  order의  $u_0$ 는 분산 분석 모형에서 잔차 모차함으로 생각!

-  $i = 0, 1, \dots, r$  일 때 분산  $\sigma_i^2$ 은 Variance Components 라고 부름

why? 개별 관측치의 분산 성분이니까!

$$\text{Var}(y_{tijk}) = \sigma_s^2 + \sigma_c^2 + \sigma^2.$$

## d. An LMM for Longitudinal data

- 종단자료 (longitudinal data)는 각 관측 단위 집합에 대해 연속적인 관측치.

ex) 환자 그룹에 대해 주차별 혈당 측정 자료

-  $y_i$ :  $i$ 환자에 대한  $n_i$ 측정값에 관한 vec.

$$E(y_i | u_i) = X_i \beta + Z_i u_i$$

$$6 \times 2 = 12$$

```

input_size = 1024
vocab_size = len(vocab_index)
embedding_size = 64
conv_layers = [[(256, 7, 3),
                 (256, 7, 3),
                 (256, 3, -1),
                 (256, 3, -1),
                 (256, 3, -1),
                 (256, 3, -1)]]



fully_connected_layers = [(1024, 1024)]
num_of_classes = 4
dropout_p = 0.5
optimizer = 'adam'
loss = 'categorical_crossentropy'

• Embedding Layer

# Embedding weights
embedding_weights = [] # (78, 64)
embedding_weights.append(np.zeros((vocab_size), # (78, 64)


```

conv-layer = [filter\_num, filter\_size, pooling\_size]


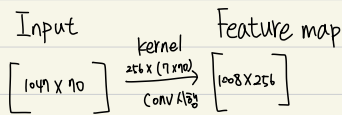




filter\_num = 256

filter\_size = 7



Layer (type)	Output Shape	Param #
Input (InputLayer)	(None, 1014, 69)	0
embedding (Embedding)	(None, 1014, 64)	78 * 64 = 5000
conv1d (Conv1D)	(None, 1008, 256)	256 * 7 * 3 = 5040
activation (Activation)	relu (None, 1008, 256)	0
max_pooling1d (MaxPooling1D)	(None, 336, 256)	0
conv1d_1 (Conv1D)	(None, 330, 256)	459008
activation_1 (Activation)	(None, 330, 256)	0
max_pooling1d_1 (MaxPooling1D)	(None, 110, 256)	0
conv1d_2 (Conv1D)	(None, 108, 256)	196864
activation_2 (Activation)	(None, 108, 256)	0
conv1d_3 (Conv1D)	(None, 106, 256)	196864
activation_3 (Activation)	(None, 106, 256)	0
conv1d_4 (Conv1D)	(None, 104, 256)	196864
activation_4 (Activation)	(None, 104, 256)	0
conv1d_5 (Conv1D)	(None, 102, 256)	196864
activation_5 (Activation)	(None, 102, 256)	0
max_pooling1d_2 (MaxPooling1D)	(None, 34, 256)	0
flatten (Flatten)	(None, 8704)	0
dense (Dense)	(None, 1024)	8913920
dropout (Dropout)	(None, 1024)	0
dense_1 (Dense)	(None, 1024)	1049600



$* 1008 = 1014 - 7 + 1$





Input

kernel  
:  $256 \times (7 \times 7)$

Feature Map

$$* 1008 = 1014 - 7 + 1$$

